

Ollama

Téléchargez et installez ollama : <https://ollama.com/download>

Commandes utiles :

ollama --version (version d'ollama)

ollama list (liste des modèles téléchargés)

ollama pull llama3.2:3b (installer le modèle llama3.2 avec 3 milliards de paramètres)

ollama run llama3.2:3b (pour lancer le modèle llama3.2 :3b)

ollama serve (pour redémarrer le serveur si besoin)

ollama rm <nom_du_modele> (pour supprimer un modèle du disque dur)

ollama ps (affiche les modèles chargés en mémoire, donc actifs)

ollama stop <nom_du_modele> (pour décharger un modèle en mémoire)

Test dans le terminal windows avec la commande Curl :

```
curl.exe http://localhost:11434/api/generate -H "Content-Type: application/json"
-d '{"model":"llama3.2:3b","prompt":"Pourquoi le ciel est bleu ?","stream":false}'
```

Pour localiser physiquement vos modèles, vous devez naviguer vers l'adresse suivante : C:\Users\<VotreNomUtilisateur>\.ollama\models

Le chemin par défaut est généralement situé dans AppData\Local\Ollama. Ce choix d'emplacement permet au logiciel de fonctionner sans nécessiter de droits d'administrateur constants après l'installation initiale.

Commandes et chat en ligne :

```
>>> /?
Available Commands:
  /set      Set session variables
  /show     Show model information
  /load <model> Load a session or model
  /save <model> Save your current session
  /clear    Clear session context
  /bye      Exit
  /?, /help Help for a command
  /? shortcuts Help for keyboard shortcuts

Use "" to begin a multi-line message.

>>> "explique la photosynthèse en deux phrases"
```

Pendant que vous discutez avec le modèle, Ollama propose des commandes système spécifiques accessibles directement dans l'interface de chat. Ces commandes commencent par un slash /. Elles permettent de modifier le comportement de la session sans avoir à relancer le programme. Par exemple, la commande `/set` permet d'ajuster des paramètres techniques comme la température, qui définit le degré de créativité de l'IA.

Voici les commandes les plus utiles lors d'une session :

`/show info` : Affiche les détails techniques du modèle chargé.

`/set verbose` : Permet de voir le temps de réponse et les statistiques de calcul.

`/clear` : Efface le contexte de la discussion pour repartir sur une base neuve.

Paramètres utiles :

`/set parameter temperature 0.2`

`/set parameter top_p 0.9`

`/set parameter top_k 40`

`/set parameter min_p 0.05`

`/set parameter seed 42`

`/set parameter num_predict 512`

`/set parameter num_ctx 8192`

`/set parameter repeat_penalty 1.1`

`/set parameter stop "</s>"`

Exemple de fonctionnement :

`ollama run llama3.2:3b`

`>>> /set system "Tu es un assistant scientifique précis. Réponds en français."`

`>>> /set parameter temperature 0.2`

`>>> /set parameter seed 42`

`>>> /set parameter num_ctx 8192`

`>>> /set verbose`

`>>> Explique la différence entre attention et SSM.`

>>> /clear

>>> Quel est le rôle de l'attention ?

>>> /bye

Trouvez des modèles pour ollama :

<https://ollama.com/search> (les plus récents, les plus populaires)

La documentation :

<https://docs.ollama.com/>

ModelFile

Créer un fichier ModelFile (sans extension ou sinon .txt) pour rendre permanent les paramètres du modèle (le message système, la température, la graine et la fenêtre de contexte, etc.).

Par exemple avec notepad, dans cmd :

notepad Modelfile

Copier/coller le contenu ci-dessous :

```
FROM llama3.2:3b
SYSTEM """
Tu es un assistant scientifique précis.
Réponds exclusivement en français.
Explique les notions avec rigueur, en distinguant les hypothèses,
les limites et les faits établis.
"""
PARAMETER temperature 0.2
PARAMETER seed 42
PARAMETER num_ctx 8192
```

Enregistrez le fichier puis, dans le même dossier :

ollama create llama32-scientifique:3b -f .\Modelfile

Ensuite, utilisez votre modèle personnalisé :

ollama run llama32-scientifique:3b

Le nom llama32-scientifique:3b est local et librement choisi ; ollama create construit une nouvelle entrée de modèle à partir du modèle de base et des instructions du fichier.

Mode verbeux

/set verbose est une préférence de l'interface interactive, pas un paramètre de génération à inscrire dans un Modelfile. Activez-le au lancement ou dans chaque session :

```
ollama run --verbose llama32-scientifique:3b
```

ou : >>> /set verbose

Vérifier la configuration :

```
ollama show --modelfile llama32-scientifique:3b
```

```
ollama show llama32-scientifique:3b
```

La première commande affiche le Modelfile correspondant; la seconde affiche notamment les paramètres du modèle.

Sous Windows, créez par exemple :

```
C:\Users\Olivier\ollama\Modelfile
```

Interface web :


Liste d'interfaces possibles :

Solution	À privilégier pour	Points forts	Limites
Open WebUI	Interface générale, recherche, prototypage d'agents et RAG local	Intégration Ollama native, chat multi-modèles, fichiers, RAG, outils Python, MCP, automatisations et support multi-utilisateurs. docs.openwebui+1	Plus lourd et plus vaste à administrer qu'un simple chat
AnythingLLM	RAG documentaire focalisé, espaces de travail par projet	Connexion directe à Ollama pour LLM et embeddings, organisation par workspaces et approche orientée bases de connaissances. docs.anythingllm+1	Moins adapté comme plateforme extensible généraliste
LibreChat	Une interface proche de ChatGPT, avec	Ollama est configurable comme endpoint et l'interface gère aussi des API compatibles OpenAI.	Intégration Ollama moins riche que celle

	plusieurs fournisseurs	librechat	d'Open WebUI
Ollama seul	Tests API, scripts et benchmarking minimaliste	Très léger, simple, robuste pour servir le modèle localement. ollama	Pas de véritable interface Web, ni gestion documentaire intégrée

Mais nous installerons l'extension **Page Assist** sous Chrome ou Firefox :

<https://chromewebstore.google.com/detail/page-assist-a-web-ui-for/jfgfiigpkhlkbnfnbobbkinehhfdhndo?hl=fr>



Simple et pratique avec des possibilités.

Page Assist est open source, avec une licence MIT, une licence permissive qui autorise l'utilisation, la modification et la redistribution du code sous réserve de conserver l'avis de licence.

Le dépôt principal est public sur GitHub : <https://github.com/n4ze3m/page-assist>. Il fournit une extension navigateur avec une barre latérale et une Web UI pour interagir avec des modèles locaux, notamment via Ollama

Lien vidéo Introduction à Ollama :

<https://www.youtube.com/watch?v=Pbjy5yXhfM&list=PLSYhtt87oGALLAeLS9SEtMru-kdpiza9u>

Comparaisons Open WebUI / AnythingLLM / Page Assist

Critère	Open WebUI	AnythingLLM	Page Assist
Nature	Application Web auto-hébergée, généraliste et extensible.	Application auto-hébergée centrée sur les documents, workspaces et agents no-code.	Extension de navigateur avec sidebar et Web UI légère.
Cible principale	Hub de chat local/privé multi-modèles, intégrations et outils.	Chat fondé sur bases de connaissances séparées par projet ou équipe.	Interroger et résumer la page ou le PDF actuellement consulté.
Intégration Ollama	Native, avec proxy des API Ollama et compatibilité OpenAI.	Fournisseur local pour LLM et embeddings ; import de tags Ollama.	Connexion à Ollama local et gestion légère des modèles.
Déploiement	Docker recommandé ; adapté à un serveur local ou LAN.	Desktop ou Docker ; prise en main plus directe pour une base documentaire.	Installation depuis le store du navigateur, donc la plus simple.
Multi-utilisateur	Oui : comptes, groupes, permissions fines et intégration d'identité.	Oui, mais son organisation centrale est le workspace/document.	Non : usage principalement personnel dans le navigateur.

Besoin	Meilleur choix	Pourquoi
Questionner un article Web au fil de la lecture	Page Assist	Accède directement au contexte de l'onglet et propose une sidebar.
Organiser des corpus distincts de PDF et notes par projet	AnythingLLM	Le workspace est l'unité de base du produit et isole documents et réglages.
RAG configurable et expérimental	Open WebUI	Choix de moteurs d'extraction, bases vectorielles, recherche hybride et reranking.
Connecter des API, MCP, scripts et fonctions Python	Open WebUI	Environnement d'outils extensible ; prudence, les outils Python peuvent exécuter du code serveur.
Monter vite un agent documentaire sans coder	AnythingLLM	Agents et constructeur no-code sont intégrés.
Gérer comptes, rôles et accès aux modèles	Open WebUI	RBAC et groupes sont des fonctions natives.

Architecture conseillée

Pour votre poste Windows avec Ollama, conservez Ollama comme serveur de modèles local et ajoutez :

Navigateur — Page Assist —┐

└— Ollama : llama3.2, embeddings, vision

Open WebUI —————┐

└— Corpus et services locaux : PDF, FastAPI, MCP

AnythingLLM — workspaces —┘

Installez d'abord Open WebUI si vous ne souhaitez déployer qu'une application : il couvre chat, RAG, modèles multiples et extensions. Ajoutez ensuite Page Assist pour l'analyse immédiate des pages, et ne déployez AnythingLLM que si l'organisation en workspaces documentaires et l'agent builder vous apportent un avantage concret.